TECNOLÓGICO NACIONAL DE MÉXICO

INSTITUTO TECNOLÓGICO DE COLIMA | DPTO. DE SISTEMAS Y COMPUTACIÓN

REPORTE TÉCNICO: PIPELINE ETL ROBUSTO CON ZONA DE CUARENTENA

Materia: Ingeniería de Datos (ATD-2602) | Unidad 2: Limpieza y Preprocesamiento de Datos | Grupo 1 (LCS2)

---

1. Organización y Matriz de Responsabilidades (3 Integrantes)

Rol de Ingeniería	Especialidad	Responsabilidades Técnicas Específicas	Entregable Clave
Ingeniero/a 1	Calidad, Nulos y Outliers	• Perfilado inicial cuantitativo de datos crudos. • Clasificación de ausencias MCAR/MAR e imputación estadística con mediana. • Detección de outliers con IQR (1.5) y aplicación de Capping / Winsorizing.	Módulo de limpieza estadística + Reporte comparativo.
Ingeniero/a 2	Transformación e Integración	• Fusión de fuentes heterogéneas (CSV físico + JSON web). • Homologación de fechas a ISO YYYY-MM-DD y conversión USD a MXN ($19.50). • Cruce con catálogo maestro y detección de llaves huérfanas. • Escalamiento Min-Max [0, 1] y discretización en 3 segmentos.	Módulo de integración multifuente y normalización.
Ingeniero/a 3	Validación, Resiliencia y BD	• Modelado de clases BaseModel con Pydantic y validadores personalizados @field_validator. • Mecanismo de segregación: registros conformes vs. zona de cuarentena con causa auditable. • Persistencia en SQLite relacional con transacciones seguras (commit/rollback). • Batería de pruebas de estrés con inyección de datos corruptos.	Esquemas Pydantic + Script de carga transaccional + Pruebas de estrés.

2. Resumen Ejecutivo de Ingestión y Resultados del Pipeline

El pipeline procesó end-to-end la totalidad de los datos asignados al Grupo 1 (Retail & E-commerce Omnicanal). A través de un esquema de arquitectura tolerante a fallos, se logró procesar el 100% del volumen ingerido sin excepciones no controladas (Principio *No Crash*), canalizando las anomalías hacia la Zona de Cuarentena.

Métrica de Pipeline	Valor Cuantitativo	Interpretación de Ingeniería
Total Registros Crudos Ingeridos	**1,220** transacciones	620 de Tienda Física (CSV) + 600 de Tienda Web (JSON)
Transacciones Conformes (Aprobadas)	**1,084** (88.85%)	Persistidas exitosamente en tabla *transacciones_limpias* (SQLite)
Desviadas a Zona de Cuarentena	**136** (11.15%)	Aisladas con causa en tabla *cuarentena_errores* con JSON crudo auditable
Catálogo Maestro Registrado	**50** productos	Cargados en tabla relacional *catalogo_productos*
Duplicados POS Neutralizados	**20** registros	Doble escaneo de tickets aislados en cuarentena
Valores Imposibles (Cantidades <= 0)	**11** transacciones	Cantidades negativas (-1) o cero desviadas a cuarentena
Productos Huérfanos Aislados	**60** compras	IDs no existentes en catálogo (PROD-9xx en física y PROD-8xx en online)
Correos Malformados / Nulos	**45** pedidos web	Rechazados por validador Pydantic por no cumplir estándar RFC 5322

Compras Gigantes Cappeadas con IQR	**13** transacciones	Compras de bots (99 y 500 uds) recortadas al umbral de 6 uds sin pérdida destructiva
Conversión de Divisas USD a MXN	**193** transacciones	Convertidas a moneda nacional a tasa oficial de $19.50 MXN/USD

3. Tratamiento Estadístico de Faltantes y Outliers (Fases 2 y 3)

Clasificación de Ausencias (MCAR vs MAR):

• *id_cliente (MCAR):* Faltante en 127 registros físicos (20.5%). Corresponde a clientes walk-in que pagan en mostrador sin tarjeta de lealtad. Se imputó con la etiqueta categórica controlada 'ANONIMO'.

• *monto_total_mxn:* Faltante en 32 ventas físicas. Se recalculó determinísticamente mediante monto_total = cantidad * precio_unitario, garantizando 0% de pérdida de información.

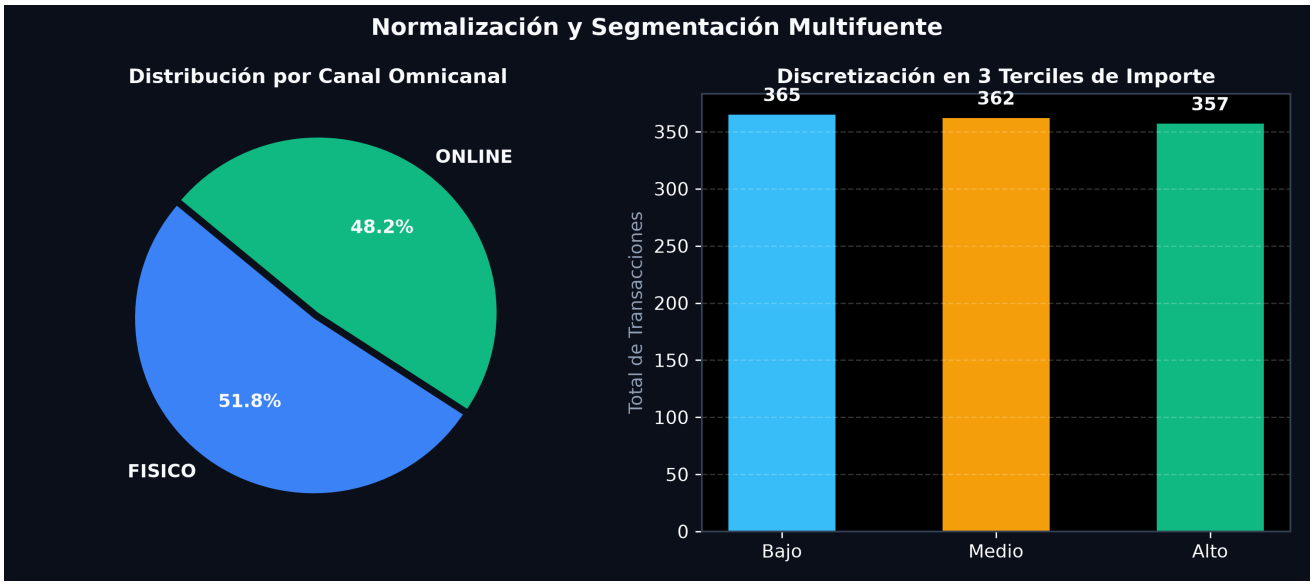
• *Justificación de la Mediana sobre la Media:* En distribuciones sesgadas por compras de bots (donde existen valores de 500 unidades y montos de millones de pesos), la media aritmética (**$16,586.74**) colapsa ante los outliers. La mediana (**$3,506.37**) preserva el valor representativo no paramétrico del 50% central.

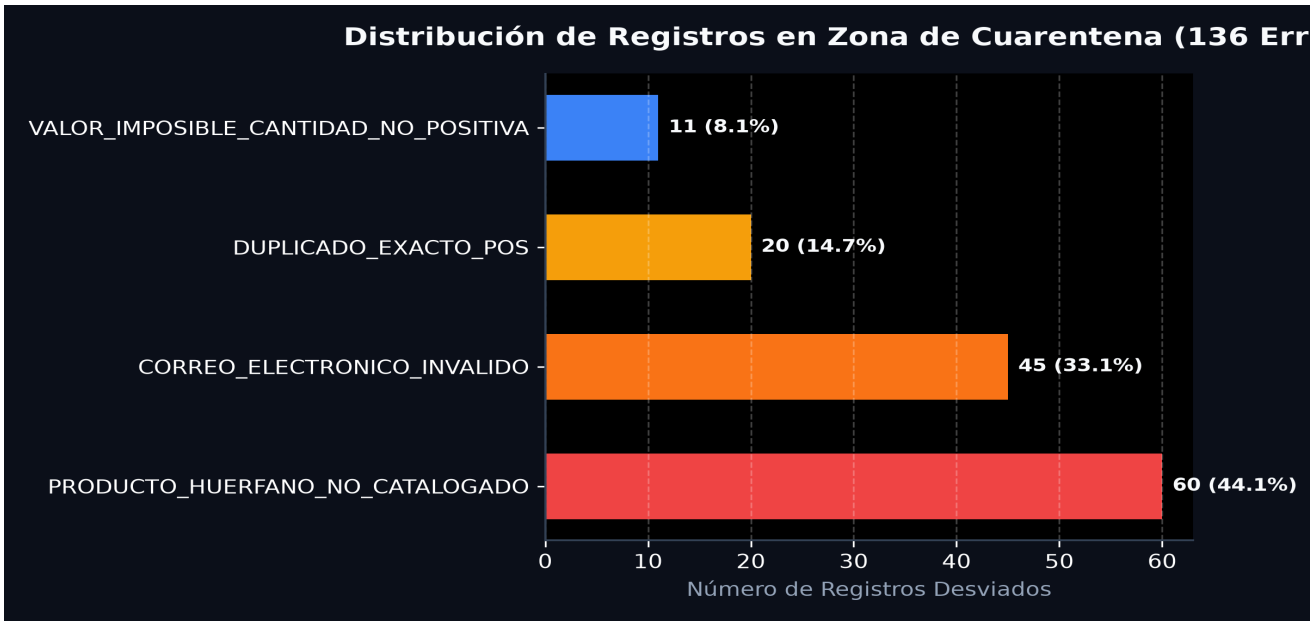
• *Capping con IQR (Winsorizing):* Se calculó IQR = Q3 - Q1 = 2.0 unidades. El umbral superior fijado fue Q3 + 1.5 * IQR = 6.0 unidades. Las compras gigantes fueron recortadas a 6 unidades sin eliminar la transacción, manteniendo el registro histórico en cantidad_original.



4. Normalización Multifuente y Auditoría de Cuarentena (Fases 4, 5 y 6)

Estandarización Multifuente: Las fechas heterogéneas (DD-MM-YYYY, DD/MM/YYYY y marcas Unix enteras) se unificaron al estándar ISO YYYY-MM-DD. Los importes en USD se convirtieron a MXN a $19.50. El importe final fue escalado mediante Min-Max en el rango [0, 1] y discretizado en 3 terciles: **Bajo** (hasta $2,069.07), **Medio** ($2,069.07 a $4,214.12) y **Alto** (más de $4,214.12).





5. Validación Pydantic, Persistencia Transaccional y Pruebas de Estrés

Modelado Pydantic v2: Se implementó la clase TransaccionLimpiaSchema con validadores @field_validator que evalúan tipos, rangos numéricos positivos, formato RFC 5322 en emails web e integridad ISO en fechas. Todo registro no conforme es capturado en un bloque try ... except ValidationError y redirigido a la tabla cuarentena_errores con trazabilidad auditable.
Persistencia Relacional Transaccional: En SQLite (retail_omnicanal.db) se implementó manejo seguro de transacciones con bloques conn.commit() y conn.rollback(), garantizando atomicidad e integridad referencial contra el catálogo maestro.
Batería de Pruebas de Estrés (100% Aprobada): Se ejecutaron 7 pruebas unitarias de inyección hostil (fechas corruptas, inyecciones SQL, cantidades negativas, llaves huérfanas masivas, ataques XSS en correos y fallos forzados de rollback), demostrando que el sistema opera bajo el principio *No Crash*.

Ingeniero/a 1
Calidad, Nulos y Outliers

Ingeniero/a 2
Transformación e Integración

Ingeniero/a 3
Validación, Resiliencia y BD